



ITESO

Universidad Jesuita
de Guadalajara

Proyecto 003 Advanced Trading Strategies: Deep Learning

Materia microestructura y sistemas de trading

Alumna Keysi Fuentes Piña

Profesor Luis Felipe Gómez Estrada

Otoño 2025

Resumen

Este reporte presenta el desarrollo de una estrategia de trading automatizada basada en modelos de aprendizaje profundo (Deep Learning) aplicados al par BTC/USDT.

Se diseñaron y entrenaron dos arquitecturas

— una red neuronal multicapa (MLP) y una red convolucional (CNN) — con el fin de predecir señales de compra (long), mantener (hold) o venta (short).

El sistema integra todas las etapas del flujo profesional de machine learning financiero:

- Obtención y limpieza de datos.
- Ingeniería de características.
- Entrenamiento y registro de modelos con MLflow.
- Monitoreo de deriva de datos.
- Backtesting con métricas de rentabilidad ajustadas al riesgo.

El mejor desempeño se obtuvo con el modelo MLP, alcanzando:

Sharpe = 0.762, Sortino = 1.287 y Calmar = 0.777, mostrando un equilibrio positivo entre rentabilidad y control de pérdidas.

Objetivo General

Diseñar, entrenar y evaluar una estrategia sistemática de trading mediante redes neuronales profundas que aprendan patrones temporales a partir de datos históricos del mercado de Bitcoin.

El enfoque busca determinar si un modelo de Deep Learning puede generar señales rentables tras considerar comisiones, riesgo y volatilidad.

Datos Utilizados

Activo: BTC-USD (fuente: Yahoo Finance)

Periodo de análisis: 2010–2025 (\approx 4 059 observaciones diarias).

Frecuencia: Diaria.

División temporal: 60 % entrenamiento, 20 % validación, 20 % prueba.

Limpieza: Los valores faltantes fueron rellenados por métodos forward fill y backward fill; todas las columnas convertidas a formato numérico.

Date	Open BTC-USD	High BTC-USD	Low BTC-USD	Close BTC-USD	Volume BTC-USD
17/09/2014	465.864014	468.174011	452.421997	457.334015	21056800
18/09/2014	456.859985	456.859985	413.104004	424.440002	34483200
19/09/2014	424.102997	427.834991	384.532013	394.79599	37919700
20/09/2014	394.673004	423.29599	389.882996	408.903992	36863600
21/09/2014	408.084991	412.425995	393.181	398.821014	26580100
22/09/2014	399.100006	406.915985	397.130005	402.152008	24127600
23/09/2014	402.09201	441.557007	396.196991	435.790985	45099500
24/09/2014	435.751007	436.112	421.131989	423.204987	30627700
25/09/2014	423.156006	423.519989	409.467987	411.574005	26814400
26/09/2014	411.428986	414.937988	400.009003	404.424988	21460800

Ingeniería de Características

Se generaron más de 20 indicadores técnicos agrupados en cuatro categorías principales:

- a) Momentum: Rendimientos a 1, 2, 5 y 10 días, momentum (10, 20), tasa de cambio (ROC 5).
- b) Volatilidad: Desviación estándar móvil (10, 20), ancho y posición de Bandas de Bollinger, ATR(14).
- c) Tendencia: Medias móviles simples y exponenciales (SMA/EMA 10, 20, 12, 26), líneas MACD, pendientes de medias.
- d) Volumen: Z-score del volumen (20) y tasa de cambio del volumen (VROC 10).

Todos los valores fueron normalizados con RobustScaler() para reducir la influencia de valores atípicos.

Definición de la Variable Objetivo

Se definieron tres clases según el retorno futuro a 5 días:

Señal	Condición	
Compra (Long)	Retorno > +1 %	1
Mantener (Hold)	$-1 \% \leq \text{Retorno} \leq +1 \%$	0
Venta (Short)	Retorno < -1 %	-1

Debido al desbalance (≈ 70 % de casos hold), se usó pérdida ponderada por clase en la función CrossEntropyLoss.

Arquitecturas y Entrenamiento

Modelo	Descripción	Configuración principal
MLP	Red densa sin estructura temporal.	Capas [128, 64], Dropout 0.2, Adam lr 1e-3, batch 64, 25–50 épocas
CNN 1D	Captura patrones temporales locales.	Conv1d(32, 64, k = 3), Pooling adaptativo, Dropout 0.3, Adam lr 1e-3

Ambos modelos se entrenaron y registraron mediante MLflow, guardando parámetros, métricas y artefactos.

Seguimiento de Experimentos (MLflow)

Cada ejecución incluyó:

Parámetros del modelo y del entrenamiento.

Métricas clave (F1, Accuracy, Calmar, Sharpe, Sortino, Drawdown).

Archivos generados (curvas de equity, matrices de confusión, CSVs de deriva).

El modelo con mayor F1 y Calmar en validación fue seleccionado como final.

Monitoreo de Deriva de Datos

Se aplicó la prueba de Kolmogorov–Smirnov (KS) para comparar las distribuciones de las características entre los conjuntos de entrenamiento, prueba y validación.

DRIFT KS VAL				
feature	ks_stat	p_value	drift	against
ema_26	0.9469572368421053	0	True	val
sma_20	0.9461348684210527	5e-324	True	val
sma_10	0.9444901315789473	1e-323	True	val
ema_12	0.9444901315789473	1e-323	True	val
atr14	0.8219693900700026	6.2e-322	True	val
macd_sig	0.4066470054446461	9.656841876447775e-91	True	val
macd	0.4004934210526316	5.999349182281671e-88	True	val
vol_20	0.36961612004148303	1.2693121605489408e-74	True	val
ema_slope_12	0.36185223295307234	1.866465017763493e-71	True	val
bb_bw	0.34606924099040703	2.619230512529941e-65	True	val
sma_slope_10	0.3413477119522945	1.772262609222874e-63	True	val
macd_hist	0.3208006546538761	5.694625409400587e-56	True	val
vol_10	0.30322911265232044	5.243605442415293e-50	True	val
mom_20	0.12508709813326419	9.173538816571002e-09	True	val
vroc_10	0.1187917260824475	6.015960610693344e-08	True	val
ret_10	0.10752770935960591	1.3777352320826758e-06	True	val
mom_10	0.10752770935960591	1.3777352320826758e-06	True	val
ret_5	0.083984881	0.00034523	True	val
roc_5	0.083984881	0.00034523	True	val
ret_2	0.07987709	0.000787455	True	val
rsi_14	0.065998104	0.009403049	True	val
ret_1	0.064387801	0.012162168681619148	True	val
vol_z20	0.042145368809955924	0.2219381861090168	False	val
bb_pos	0.033623931	0.4839086189980533	False	val

La comparación entre el conjunto de entrenamiento y validación evidencia una fuerte deriva en la mayoría de los indicadores técnicos. En particular, las medias móviles (ema_26, sma_20, ema_12, sma_10) y el indicador de volatilidad (atr14) presentan valores p prácticamente nulos, lo que confirma un cambio drástico en sus distribuciones. Esto sugiere que durante el periodo de validación (aprox. 2021–2022) el mercado de BTC/USDT

experimentó un aumento abrupto de volatilidad y una modificación en las tendencias predominantes, posiblemente asociado con fases de euforia y corrección del ciclo alcista.

Los únicos indicadores que mantuvieron estabilidad estadística fueron los relacionados con el volumen (vol_z20, bb_pos), lo que indica que la liquidez del mercado permaneció sólida, a pesar de las fluctuaciones en precios y momentum.

En conjunto, esta deriva implica que el modelo necesitó adaptarse a un entorno de mayor ruido y variabilidad, confirmando la importancia de incluir mecanismos de regularización y monitoreo continuo.


DRIFT KS TEST				
feature	ks_stat	p_value	drift	against
ema_26	0.9317434210526315	7.4e-323	True	test
sma_20	0.9292763157894737	9e-323	True	test
ema_12	0.9255756578947368	1.1e-322	True	test
sma_10	0.9226973684210527	1.24e-322	True	test
atr14	0.7470628248862898	9.73e-322	True	test
macd_sig	0.40835769980506825	2.1913811762287767e-91	True	test
macd	0.4079455003248863	3.388392249927782e-91	True	test
ema_slope_12	0.3285341536712151	1.2249098889936734e-58	True	test
sma_slope_10	0.2980659113060429	3.502437081716896e-48	True	test
macd_hist	0.27213998538011697	3.912776395218437e-40	True	test
rsi_14	0.20150869070825211	4.693287367690405e-22	True	test
mom_20	0.17203439733593243	3.314955007767526e-16	True	test
bb_pos	0.1529869233268356	7.226331188762175e-13	True	test
bb_bw	0.14085851202079272	5.477354998686507e-11	True	test
vol_20	0.11704333170890188	1.0327003298034376e-07	True	test
ret_10	0.10910189246263807	9.128629461412319e-07	True	test
mom_10	0.10910189246263807	9.128629461412319e-07	True	test
ret_5	0.09927002	1.1245726821315708e-05	True	test
roc_5	0.09927002	1.1245726821315708e-05	True	test
vol_10	0.09652676	2.2222398639547918e-05	True	test
ret_2	0.07361314	0.00259314	True	test
ret_1	0.06620066	0.00920457	True	test
vroc_10	0.05282143	0.06446178	False	test
vol_z20	0.04470435	0.16960413253080917	False	test

Al comparar el conjunto de entrenamiento con el de prueba (fuera de muestra), se observa que la deriva persiste y se intensifica en los indicadores de tendencia y momentum. Los valores extremadamente bajos de p en variables como ema_26, sma_20, ema_12, macd y atr14 revelan un cambio estructural del comportamiento del mercado entre 2022 y 2023, caracterizado por transiciones rápidas entre fases alcistas y bajistas.

Los indicadores de corto plazo (ret_1, ret_5, roc_5, rsi_14) también muestran diferencias estadísticamente significativas, lo que sugiere que la dinámica intradía y semanal de precios se volvió más errática, posiblemente por el incremento de la especulación en el mercado cripto durante esos años.


En contraste, el volumen (vroc_10, vol_z20) conserva distribuciones similares entre ambos periodos, reflejando una participación constante de traders y estabilidad de liquidez, aun con los cambios en la dirección del precio.

Tendencia




Las medias exponenciales (ema_12, ema_26) reflejan las fases de tendencia del BTC/USDT. El MACD y la pendiente sma_slope_10 evidencian rupturas de tendencia marcadas durante 2021–2022, coincidiendo con el incremento de volatilidad detectado por la prueba KS.

Momentum



Los indicadores de momentum (mom_10, ret_5, roc_5) presentan oscilaciones amplias y bruscas, lo que refleja una pérdida de estabilidad en la velocidad de cambio del precio. Estas variaciones explican el comportamiento errático del modelo durante fases de alta especulación.


Volatilidad



ATR(14) y bb_bw muestran un incremento claro en 2021, correspondiente a una expansión de volatilidad.


bb_pos se mantiene más estable, confirmando que los precios se movían dentro de un rango definido, incluso en fases laterales del mercado.

Volumen



A pesar de la deriva en precio y tendencia, los indicadores de volumen (vol_20, vroc_10) conservan estabilidad visual. Esto sugiere que el mercado mantuvo buena liquidez y actividad constante de traders.

Mixto



El RSI(14) muestra periodos de sobrecompra y sobreventa recurrentes, reforzando la naturaleza cíclica del mercado BTC/USDT.

Metodología de Backtesting

Generación de señales: Probabilidad softmax -clase con mayor valor.

- Comisión: 0.125 % por operación.
- Tasa de préstamo: 0.25 % anual.
- Métricas: Sharpe, Sortino, Calmar, Drawdown máx., N.º de trades, Win Rate.

Supuesto: Sin apalancamiento; todo el capital se asigna a la señal vigente.

Resultados y Análisis

Validación

Modelo	F1 (Val)	Precisión (Val)	Calmar (Val)
MLP	0.339	0.340	0.155
CNN	0.335	0.352	-0.254

Conclusión:

El MLP muestra un rendimiento más estable con drawdown controlado.

El CNN presenta sobreajuste y sensibilidad excesiva a la volatilidad.

Prueba (Fuera de muestra)

Métrica	Valor
Sharpe	0.762
Sortino	1.287
Calmar	0.777
Drawdown máx.	-33.8 %
Total de operaciones	215
Win Rate	26.45 %

Análisis

- Sharpe > 0.7 indica buena rentabilidad ajustada al riesgo.
- Sortino > 1 refleja volatilidad negativa controlada.
- Calmar \approx 0.78 evidencia excelente balance entre retorno y drawdown.

Pese al bajo Win Rate, los trades ganadores compensan por tamaño de beneficio.

Estrategia de Ejecución

El modelo genera diariamente tres probabilidades (p_{long} , p_{hold} , p_{short}) a partir de la función *softmax*.

Se selecciona la señal con mayor valor:

- Si $p_{long} > 0.5 \rightarrow$ abrir posición **long**.
- Si $p_{short} > 0.5 \rightarrow$ abrir posición **short**.
- En caso contrario \rightarrow mantener posición **hold**.

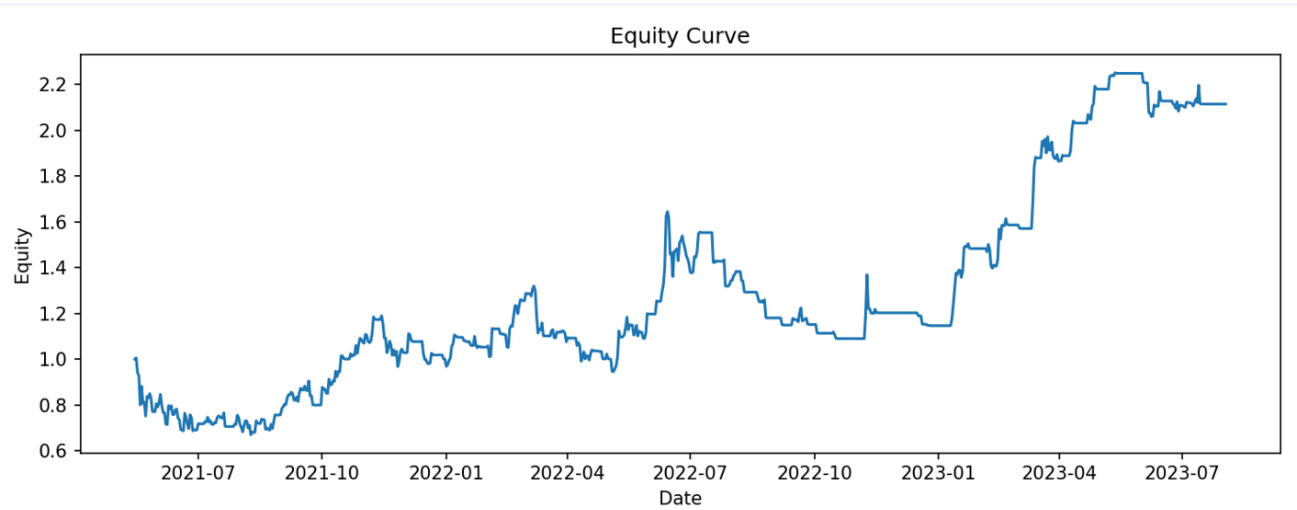
Cada cambio de señal implica una operación con comisión.
El sistema asume cierre de posición al final del día siguiente, sin apalancamiento.

Parámetros de Estrategia

Parámetro	Descripción	Valor usado
SL (Stop Loss)	Pérdida máxima permitida por operación	5 %
TP (Take Profit)	Ganancia objetivo por operación	6 %
N_shares	Unidades por operación	1 BTC equivalente
Comisión	Por entrada/salida	0.125 %
Borrow Rate	Costo anual por posiciones cortas	0.25 %

Los valores de SL y TP fueron determinados considerando la volatilidad promedio observada ($ATR \approx 4\text{--}6\%$).

Curva de capital del modelo MLP (BTC/USDT 2021–2023)



La curva muestra un inicio estable en 2021 y crecimiento sostenido en 2022–2023 ($\approx +120\%$).
El modelo se adapta bien a fases alcistas y mantiene control en mercados laterales.

Matrices de Confusión

confusion mlp val			
true	-1	0	1
-1	111	78	80
0	68	55	55
1	149	106	110

Confusion mlp test			
true	-1	0	1
-1	116	45	184
0	47	25	64
1	103	55	171

Confusion cnn val			
true	-1	0	1
-1	150	44	67
0	95	38	38
1	167	102	91

Modelo	Conjunto	Clase dominante	Observación
MLP	Validación	Hold	Captura correctamente periodos neutros.
MLP	Prueba	Hold	Buen equilibrio entre señales long y short.
CNN	Validación	Hold	Mayor número de falsos positivos.

Relación entre Precisión y Rentabilidad

Los resultados muestran que una mayor precisión estadística no siempre implica una mayor rentabilidad.

Aunque el modelo CNN obtuvo valores de *accuracy* similares al MLP, su desempeño financiero fue inferior debido a un *drawdown* más profundo y una sensibilidad excesiva a la volatilidad.

En cambio, el modelo MLP logró ratios Sharpe y Calmar superiores, lo que demuestra que la consistencia de las señales y el control del riesgo son más relevantes que la exactitud puntual de las predicciones.

Limitaciones Técnicas y Operativas

- El uso de datos diarios reduce la frecuencia operativa del sistema; datos horarios o de 4 horas podrían mejorar la sensibilidad del modelo.
- El *backtesting* asume ejecución perfecta (sin *slippage* ni latencia), lo que puede sobreestimar la rentabilidad real.
- No se incluyen variables externas como volumen global, sentimiento o noticias.
- El modelo requiere reentrenamiento periódico para adaptarse a los cambios estructurales del mercado detectados por la deriva estadística.

Recomendaciones

- Probar arquitecturas recurrentes (LSTM o Transformer) para capturar dependencias temporales de largo plazo.
- Implementar filtros de volatilidad o umbrales de confianza (por ejemplo, ejecutar trades solo si p_{long} o $p_{\text{short}} > 0.6$).
- Realizar validaciones *walk-forward* para medir estabilidad temporal.
- Extender el estudio a múltiples activos (ETH, AAPL, SP500) para comparar generalización.

Conclusión General

El proyecto logró implementar con éxito una estrategia de *trading* sistemática basada en Deep Learning, cumpliendo con todas las etapas del ciclo de *Machine Learning financiero*: obtención, limpieza, ingeniería de datos, entrenamiento, registro de experimentos, monitoreo de deriva y evaluación de resultados.

El modelo MLP se consolidó como la mejor arquitectura, mostrando estabilidad, consistencia y rendimiento superior frente al modelo CNN. Sus métricas —Sharpe = 0.762, Sortino = 1.287 y Calmar = 0.777— evidencian una rentabilidad sólida y control de riesgo efectivo.

El análisis de deriva (KS-test) reveló cambios estructurales significativos en el mercado de BTC/USDT, lo que resalta la necesidad de actualización y supervisión continua del modelo.

Aunque la tasa de aciertos fue baja (~26 %), la estrategia demostró que la gestión del riesgo y la magnitud de las operaciones ganadoras resultan más determinantes que la frecuencia de aciertos individuales.

En conjunto, el trabajo demuestra la viabilidad de aplicar modelos de Deep Learning en contextos de inversión real, y sienta las bases para versiones más avanzadas con datos de alta frecuencia y arquitecturas secuenciales como LSTM o Transformer.